Deskryptory sieciowe

jako narzędzia rozróżniające ludzkie i zwierzęce sieci społecznościowe

Michał Dobranowski

czerwiec 2023

Spis treści

1 Wstęp i oznaczenia **2**
1.1 Deskryptory sieciowe 2

2 Deskryptory w modelach sieci losowych **2**
2.1 Model Erdősa-Rényi'ego 2
2.2 Model Wattsa-Strogatza 3
2.3 Model Barabásiego-Albert 3

3 Deskryptory w sieciach rzeczywistych **3**
3.1 Sieci zwierzęce 5
3.1.1 Delfiny butlonose 5
3.1.2 Hieny cętkowane 5
3.1.3 Myszy domowe 5
3.2 Sieci ludzkie 7
3.2.1 Użytkownicy Facebooka 7
3.2.2 Użytkownicy Twitcha 7

4 Wnioski **7**

Bibliografia **8**

1 Wstęp i oznaczenia

Jeśli nie zaznaczono inaczej, to przez V będziemy oznaczać zbiór n wierzchołków w grafie, a przez E zbiór m krawędzi. Ponadto, $\deg(v)$ oznacza stopień wierzchołka v (czyli liczbę jego sąsiadów). Przez *graf* rozumiemy nieskierowany nieważony graf prosty, rozważamy jednak również grafy ważone, to znaczy z przypisanymi wagami do jego krawędzi.

1.1 Deskryptory sieciowe

Rozkład stopni wierzchołków

$$P(k) = \frac{n_k}{n},$$

gdzie n_k to liczba wierzchołków o stopniu k.

Clustering coefficient

$$C(v) = \frac{T(v)}{\deg(v)(\deg(v) - 1)},$$

gdzie $T(v)$ to liczba trójkątów K_3 zawierających v. Jest miarą tego, jak wiele sąsiadów danego wierzchołka jest połączonych; pozwala ocenić, czy w sieci występują grupy wierzchołków połączonych ze sobą (klastry).

Closeness centrality

$$C_C(v) = \frac{1}{\sum\limits_{t \in V} d_G(v,t)},$$

gdzie $d_G(v,t)$ to odległość od wierzchołka v do t (czyli długość najkrószej ścieżki między nimi). Określa, jak blisko znajduje się dany węzeł do wszystkich innych węzłów w sieci, a więc jak łatwo z danego wierzchołka możemy osiągnąć inne wierzchołki.

Betweenness centrality

$$C_B(v) = \sum_{s \neq v \neq t} \frac{\sigma_{st}(v)}{\sigma_{st}},$$

gdzie σ_{st} to liczba najkrótszych ścieżek między wierzchołkami s, t, a $\sigma_{st}(v)$ to liczba najkrótszych ścieżek między wierzchołkami s, t, które przechodzą przez wierzchołek $v \neq s, t$. Ta miara opisuje jak istotny jest dany węzeł w komunikacji między innymi węzłami w sieci. W porównaniu do poprzednich deskryptorów, jego optymalne wyliczenie nie jest tak proste, stosuje się do tego celu algorytm Brandesa [1].

2 Deskryptory w modelach sieci losowych

W tej sekcji przedstawimy trzy standardowe modele losowych sieci oraz porównamy opisane deskryptory na ich przykładzie. Sieci zostały wygenerowane za pomocą biblioteki NetworkX [2] języka Python. Wszystkie wykresy powstały w Pythonie z użyciem bibliotek matplotlib oraz seaborn [3].

2.1 Model Erdősa-Rényi'ego

Najprostrzym modelem losowych grafów (oraz najstarszym), jest ten rozważany przez Paula Erdősa oraz Alfréda Rényi'ego [4]. Każda para wierzchołków jest jest połączona krawędzią z jednakowym prawdopodobieństwem p.

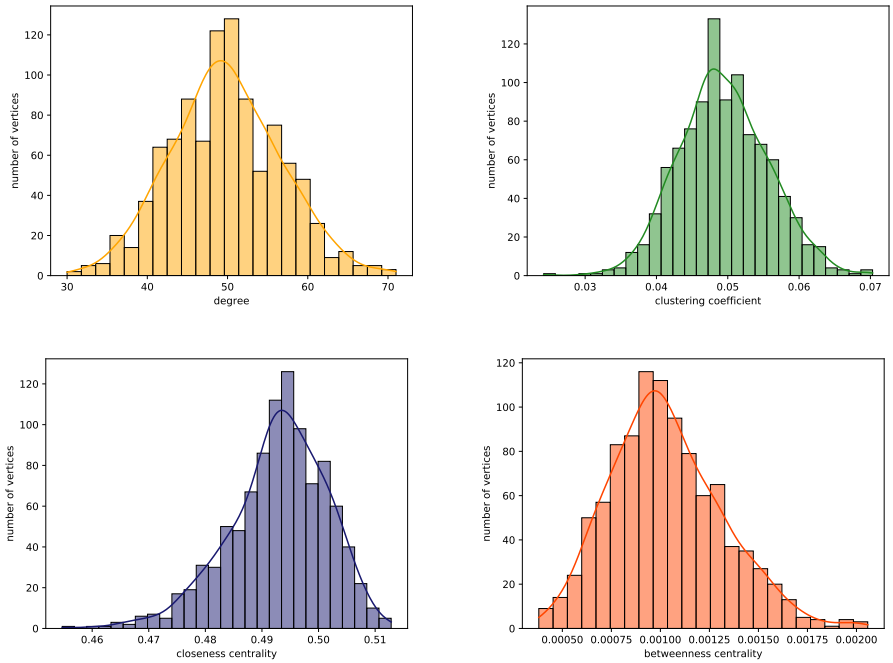

Rysunek 1: Rozkład stopni wierzchołków, *clustering coefficient*, *closeness centrality* oraz *betweenness centrality* dla grafu wygenerowanym modelem ER z $n = 1000$, $p = 0.05$.

2.2 Model Wattsa-Strogatza

Model przedstawiony przez Duncana Wattsa i Stevena Strogatza [5] charakteryzuje się małą odległością między wierzchołkami (proporcjonalną do $\log n$) oraz wysoką klasteryzacją (ma cechy sieci typu *small-world*). Algorytm tworzenia takiej sieci wygląda następująco: zaczynamy od grafu stanowiącego $\frac{k}{2}$-tą potęgę cyklu C_n. Następnie przepinamy każdą krawędź do innego wierzchołka (wybranego losowo) z prawdopodobieństwem β.

2.3 Model Barabásiego-Albert

Zaproponowany przez Alberta-László Barabásiego i Rékę Albert [6] algorytm generowania losowych grafów tworzy sieci bezskalowe (*scale-free*) to znaczy takie, w których rozkład stopni wierzchołków jest rozkładem potęgowym. Tego typu sieci tworzy się przez inkrementowanie liczby krawędzi, w każdym kroku faworyzując wierzchołki o dużym stopniu (to znaczy, że prawdopodobieństwo przyłączenia nowej krawędzi do danego wierzchołka jest wprost proporcjonalne do jego stopnia). W ten sposób otrzymujemy

$$P(k) \sim k^{-3}.$$

3 Deskryptory w sieciach rzeczywistych

W tej sekcji skupimy się na rzeczywistych sieciach społecznościowych. Dane dotyczące zwierząt pochodzą z *Animal Social Network Repository* [7]. Wszystkie pozostałe zostały zebrane w *Stanford Network Analysis Platform* [8].

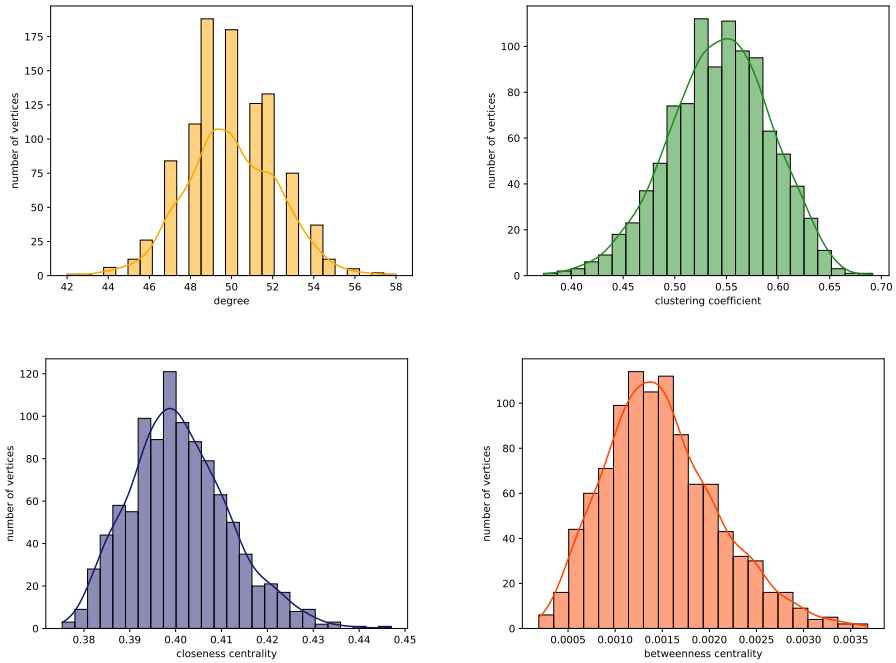

Rysunek 2: Rozkład stopni wierzchołków, $C(v)$, $C_C(v)$ oraz $C_B(v)$ dla grafu wygenerowanym modelem WS z $n = 1000$, $k = 50$, $\beta = 0.1$.

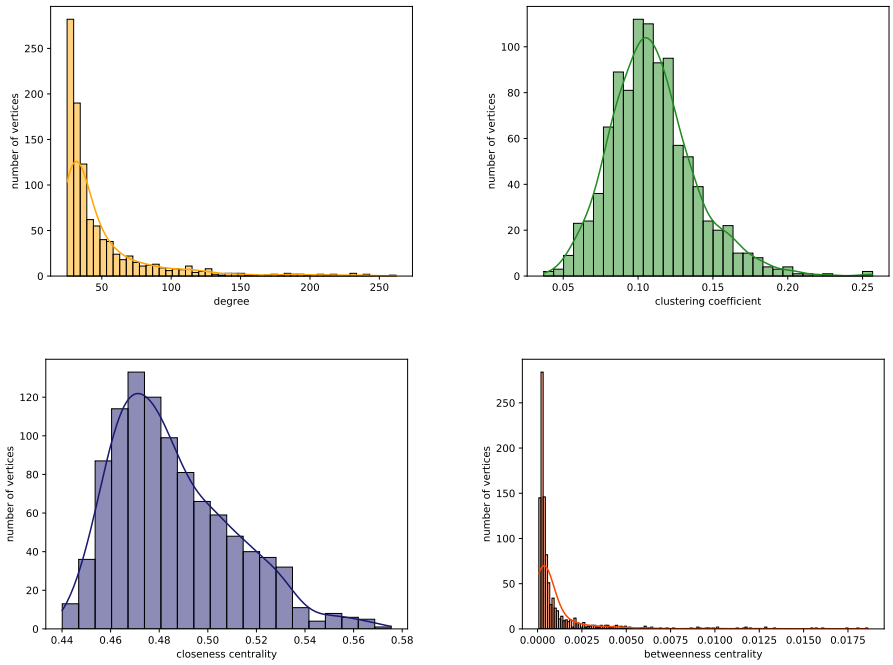

Rysunek 3: Rozkład stopni wierzchołków, $C(v)$, $C_C(v)$ oraz $C_B(v)$ dla grafu wygenerowanym modelem BA z $n = 1000$, $m = 25000$

3.1 Sieci zwierzęce

3.1.1 Delfiny butlonose

Badany graf opisuje sieć społecznościową ssaków z gatunku *Tursiops truncatus*, czyli butlonosów zwyczajnych. Wierzchołki grafu to poszczególne osobniki, które są połączone krawędzią, jeśli wchodziły ze sobą w interakcje, takie jak schwytanie zdobyczy lub nagminne przypadki poszukiwania zdobyczy. Sieć zawiera łącznie 291 węzłów połączonych 3182 krawędziami (ważonymi[1], w zależności od liczby interakcji).

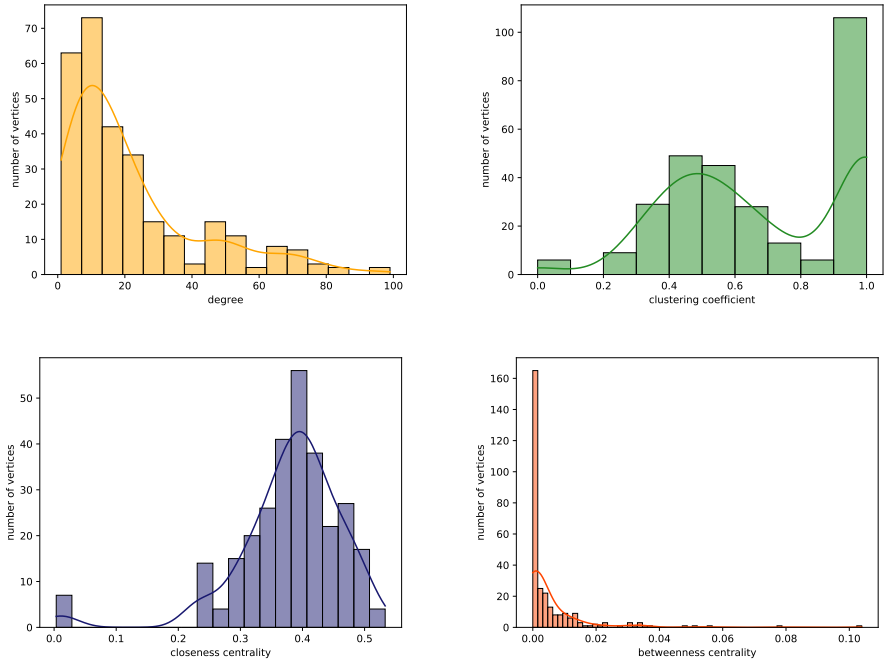

Rysunek 4: Rozkład stopni wierzchołków, $C(v)$, $C_C(v)$ oraz $C_B(v)$ dla sieci społecznościowej delfinów butlonosych.

3.1.2 Hieny cętkowane

Badany graf opisuje sieć społecznościową hien gatunku *Crocuta crocuta* (hiena cętkowana). Zawiera 35 węzłów połączonych 521 krawędziami. Dane dwie osobniki są połączone krawędziami ważonymi, w zależności od tego, jak często pojawiały się w jednej polującej grupie.

3.1.3 Myszy domowe

Bady graf opisuje społeczność 280 myszy domowych z gatunku *Mus musculus domesticus*. Krawędź między danymi dwoma osobnikami istnieje, jeśli weszły one do jednej klatki z jedzeniem w czasie obserwacji. Łącznie w sieci znajduje się 2792 krawędzi.

[1] Dostosowanie definicji poszczególnych deskryptorów nie stanowi żadnego problemu, operujemy tam tylko pojęciem odległości / długości scieżki między wierzchołkami.

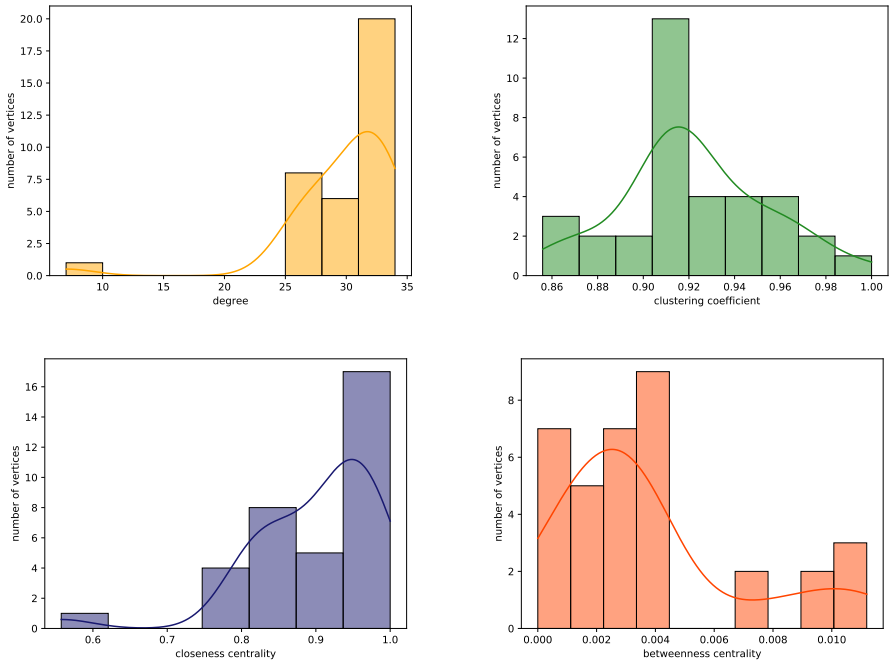

Rysunek 5: Rozkład stopni wierzchołków, $C(v)$, $C_C(v)$ oraz $C_B(v)$ dla sieci społecznościowej hien cętkowanych.

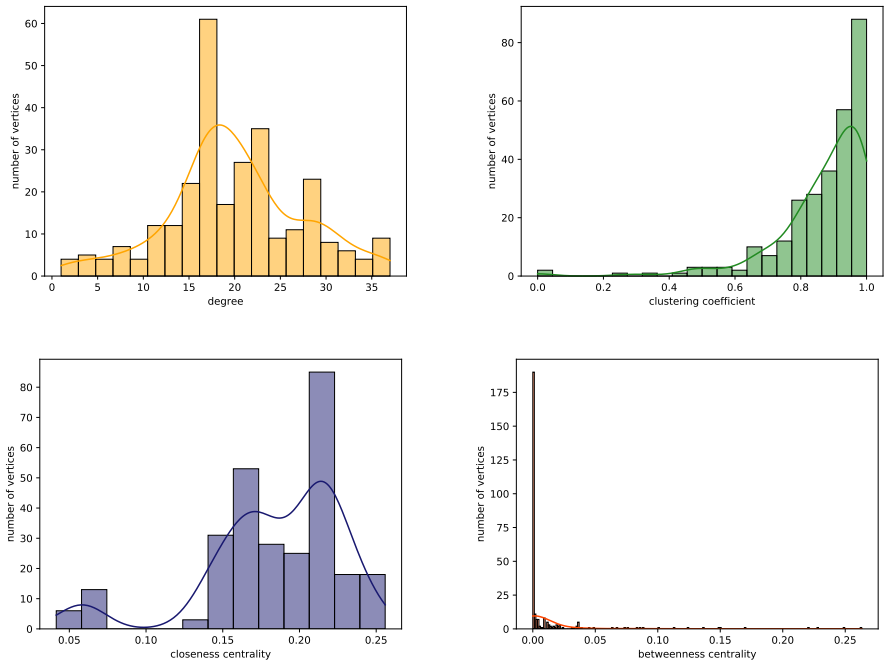

Rysunek 6: Rozkład stopni wierzchołków, $C(v)$, $C_C(v)$ oraz $C_B(v)$ dla sieci społecznościowej myszy domowych.

3.2 Sieci ludzkie

3.2.1 Użytkownicy Facebooka

Badana sieć jest siecią znajomości 224 użytkowników Facebooka, którzy zdecydowali się uzupełnić ankietę przy użyciu aplikacji mobilnej. Sieć ma łącznie 3192 krawędzie.

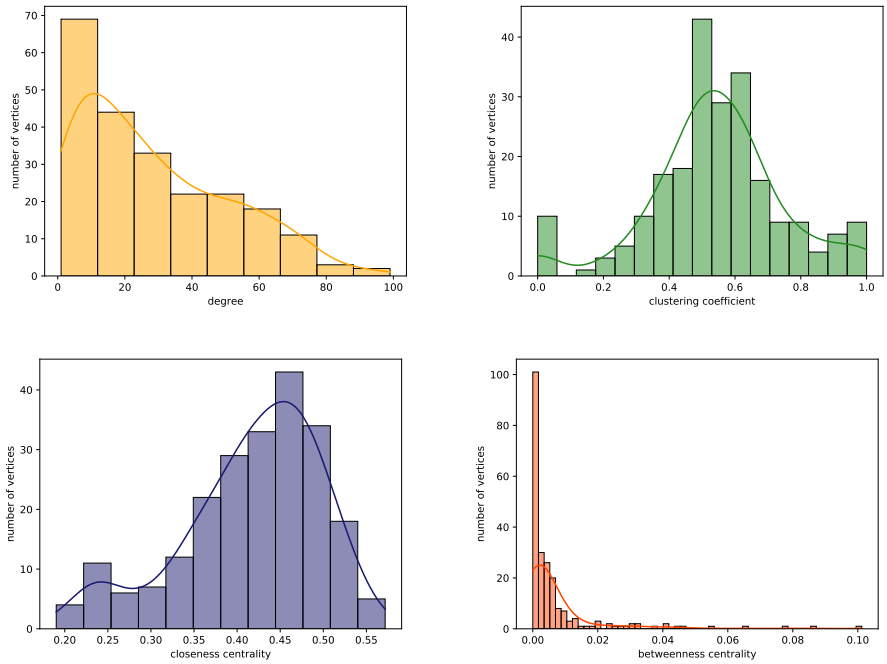

Rysunek 7: Rozkład stopni wierzchołków, $C(v)$, $C_C(v)$ oraz $C_B(v)$ dla sieci społecznościowej użytkowników Facebooka.

3.2.2 Użytkownicy Twitcha

Badana sieć jest siecią znajomości 4648 użytkowników Twitcha, którzy oglądali streamy w języku hiszpańskim. Sieć ma łącznie 59382 krawędzie.

4 Wnioski

Dosyć oczywistym wnioskiem jest fakt, że (ludzkie) sieci społecznościowe można symulować przy użyciu modelu Barabásiego-Albert. Istotnie, każda z trzech sieci (model BA, użytkownicy Facebooka, użytkownicy Twitcha) charakteryzuje się dużą liczbą wierzchołków o małych stopniach i małą liczbą tych „popularnych”; podobnie jest z rozkładem *betweenness centrality*, która to miara przyjmuje raczej małe wartości.

Od tego schematu bardzo odstają sieci opisujące relacje między hienami – te tworzą bardzo gęstą sieć, a więc wierzchołków o dużym stopniu jest bardzo dużo – oraz między myszami – tutaj z kolei rozkład stopni wierzchołków przypomina rozkład normalny.

Zdecydowanie najbardziej podobną do sieci ludzkich jest sieć delfinów. Jedynym deskryptorem, który mógłby posłużyć za miarę odróżniającą te sieci jest *clustering coefficient* – średnio zdecydowanie wyższy u delfinów, występuje też duża grupa osobników mająca ten wskaźnik bardzo wysoki, to znaczy bliski 1. Wydaje się więc, że delfiny bardzo często przynależą tylko do jednej silnie połączonej grupy osobników, w przeciwieństwie

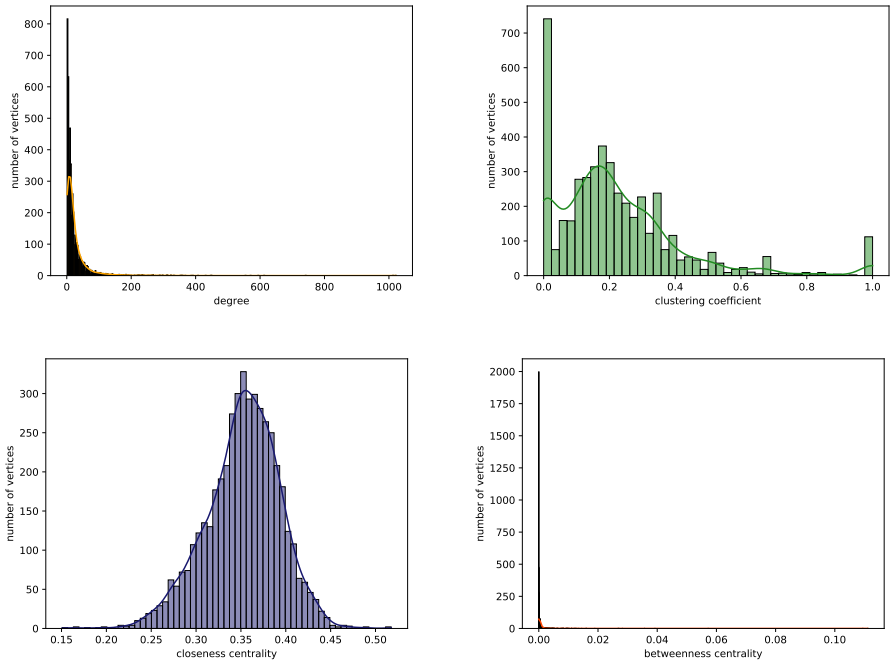

Rysunek 8: Rozkład stopni wierzchołków, $C(v)$, $C_C(v)$ oraz $C_B(v)$ dla sieci społecznościowej hiszpańskojęzycznych użytkowników Twitcha.

do ludzi, którzy często mają kilka grup znajomych lub mniej znającą się nawzajem grupę znajomych.

Bibliografia

[1] U. Brandes, "A faster algorithm for betweenness centrality," *The Journal of Mathematical Sociology*, t. 25, nr. 2, s. 163–177, 2001. DOI: 10.1080/0022250X.2001.9990249.

[2] A. A. Hagberg, D. A. Schult i P. J. Swart, "Exploring Network Structure, Dynamics, and Function using NetworkX," w *Proceedings of the 7th Python in Science Conference*, G. Varoquaux, T. Vaught i J. Millman, red., Pasadena, CA USA, 2008, s. 11–15. adr.: https://networkx.org.

[3] M. L. Waskom, "seaborn: statistical data visualization," *Journal of Open Source Software*, t. 6, nr. 60, s. 3021, 2021. DOI: 10.21105/joss.03021.

[4] P. L. Erdős i A. Rényi, "On random graphs I," *Publicationes Mathematicae*, t. 6, nr. 3-4, s. 290–297, 1959. DOI: 10.5486/PMD.1959.6.3-4.12.

[5] D. Watts i S. Strogatz, "Collective dynamics of 'small-world' networks," *Nature*, t. 393, s. 440–442, 1998. DOI: 10.1038/30918.

[6] A.-L. Barabási i R. Albert, "Emergence of Scaling in Random Networks," *Science*, t. 286, nr. 5439, s. 509–512, 1999. DOI: 10.1126/science.286.5439.509.

[7] P. Sah, J. Méndez i S. Bansal, "A multi-species repository of social networks," *Scientific Data*, t. 6, 2019. DOI: 10.1038/s41597-019-0056-z.

[8] J. Leskovec i A. Krevl, *SNAP Datasets: Stanford Large Network Dataset Collection*, 2014. adr.: http://snap.stanford.edu/data.